Market Structure Analysis: Comparing GICS Sectors vs Spectral Clustering on S&P500 Returns in Q4 2024

Simone Squizzato - n. mat. 0222401031

A.A. 2024/2025

Abstract

Il progetto esamina la relazione tra la classificazione settoriale GICS (Global Industry Classification Standard) e la struttura di correlazione effettiva dei rendimenti azionari dell'indice S&P500 nell'ultimo trimestre del 2024. Attraverso l'applicazione di tecniche di spectral clustering sui rendimenti giornalieri in eccesso delle azioni, depurati dall'effetto del mercato generale. L'analisi rivela significative divergenze tra i raggruppamenti tradizionali GICS e i pattern identificati attraverso la correlazione degli extra-rendimenti.

1 Introduzione

Quando si discute di una possibile segmentazione delle azioni presenti su un mercato si è soliti fare riferimento ai settori in cui le aziende in questione operano; le società S&P e MSCI identificano, ormai da più di 25 anni, l'ottimale suddivisione delle più grandi aziende del mondo in settori, tale suddivisione è nota con l'acronimo di GICS (Global Industry Classification Standard). Il GICS è, quindi, un sistema di classificazione industriale gerarchico a quattro livelli: Settori, Gruppi industriali, Industrie e Sottoindustrie.

Le definizioni sono standardizzate e applicate alle aziende a livello globale, inoltre a ciascuna azienda viene assegnata una singola classificazione GICS in ciascuno dei quattro livelli, in base alla sua principale attività commerciale; per farlo un fattore chiave sono i ricavi, tuttavia, anche gli utili e la percezione del mercato sono riconosciuti come informazioni importanti e rilevanti ai fini della classificazione e vengono presi in considerazione durante il processo di revisione, che avviene annualmente.[3]

Ad oggi, la classificazione GICS viene utilizzata principalmente nell'ambito della gestione e creazione di portafogli settoriali o per l'analisi delle performance di determinati settori sui mercati.

2 Metodologia

In questa sezione analizziamo in che modo sono stati raccolti e trattati i dati prima di effettuare la nostra analisi; successivamente saranno introdotte le metodologie dal punto di vista analitico.

2.1 Creazione del Dataset

La creazione del dataset utilizzato è stata possibile attraverso l'utilizzo delle informazioni presenti su Yahoo Finance[4], nello specifico i prezzi di chiusura aggiustati, per la quasi totalità delle azioni presenti all'interno dell'indice azionario S&P500, nell'ultimo trimestre del 2024. Una volta creato il dataset con i prezzi di chiusura aggiustati, si è calcolato, per una maggiore facilità di trat-

tamento, il logaritmo del prezzo giornaliero di ciascun titolo e calcolato il rendimento come la differenza tra il logaritmo dei prezzi al tempo t+1 e al tempo t; infine, è stata aggiunta una variabile contenente il GICS per ognuna delle azioni considerate. Al termine del processo di creazione, il dataset così realizzato, conta 498 osservazioni (497 azioni oltre all'indice di mercato) e 64 variabili (63 giorni di contrattazione sul mercato e il settore GICS).

2.2 Spectral Clustering

Utilizziamo lo Spectral Clustering per poter separare le azioni sulla base della loro struttura degli extra-rendimenti giornalieri, ci aspettiamo infatti che aziende facenti parte dello stesso settore, tolto l'effetto dell'intero mercato, si muovano in maniera simile. Per fare ciò, il primo passo è isolare l'effetto del mercato, quindi calcolare l'ERR (Excess Return Rate) ad un fattore, come la parte residuale di una regressione lineare tra i rendimenti delle singole azioni e il rendimento dell'indice di mercato, sulla base dell'intuizione del CAPM. Una volta calcolato l'ERR, calcoliamo il valore assoluto delle correlazioni tra i titoli considerati, queste saranno le correlazioni "reali" tra i titoli al netto dell'effetto del mercato. La matrice così creata sarà la nostra matrice di adiacenza che identifica un network non direzionato attraverso un grafo pesato, che utilizzeremo per il calcolo della matrice Laplaciana normalizzata. Nello specifico, la procedura eseguita è suddivisibile in tre step principali.

2.2.1 Calcolo dell'Excess Return Rate (ERR)

Il primo step della procedura riguarda il calcolo dell'Excess Resurn Rate, per cui sarà necessario definire il seguente modello di regressione lineare:

$$R_i = \alpha_i + \beta_i R_m + \epsilon_i \tag{1}$$

l'ERR$_i$ sarà pari al residuo ϵ_i della regressione, ossia:

$$ERR_i = \epsilon_i = R_i - (\alpha + \beta_i R_m) \tag{2}$$

2.2.2 Creazione della matrice Laplaciana

Il secondo step è suddiviso a sua volta in ulteriori passi, elencati di seguito:

1. Calcolo della matrice di correlazione R e del suo valore assoluto S (matrice di adiacenza): la matrice R è composta da 497×497 elementi del tipo $(\rho_{i,j})$ dove:

   $$\rho_{i,j} = \frac{cov(ERR_i, ERR_j)}{\sigma_i \sigma_j} \tag{3}$$

   il suo valore assoluta sarà semplicemente pari a:

   $$S = |R| \tag{4}$$

2. Calcolo del node degree (d_i):

   $$d_i = \sum_j S_{i,j} \tag{5}$$

3. Calcolo della matrice diagonale dei degree:

   $$D = Diag(d_1, \ldots, d_n) \tag{6}$$

   e della conseguente matrice $D^{-\frac{1}{2}}$:

   $$D^{-\frac{1}{2}} = Diag(\frac{1}{\sqrt{d_i}}) \tag{7}$$

4. Calcolo della matrice Laplaciana normalizzata:

   $$L = I - D^{-\frac{1}{2}} S D^{-\frac{1}{2}} \tag{8}$$

   che è una matrice semi-definita positiva.

2.2.3 Applicazione dello Spectral Clustering sulla matrice Laplaciana

L'ultimo step, anch'esso suddividibile in altre piccole operazioni si conclude con l'applicazione dell'algoritmo k-means agli autovettori della matrice Laplaciana, per fare ciò risulta però necessario concludere i seguenti passaggi:

1. Calcolo e ordinamento gli autovalori della matrice Laplaciana: una volta ordinati in senso decrescente, attraverso l'utilizzo dell'elbow criterion si sceglie un numero di autovalori (e rispettivi autovettori) G, che risulterà pari al numero di partizioni in cui suddividere le osservazioni.

2. Calcolo della matrice degli autovettori V: la quale apparterrà ad uno spazio ridotto delle features $\mathbb{R}^{n \times G}$.

3. Applicazione dell'algoritmo k-means (approssimazione di Lloyd[1]) con k = G = 11, numero di settori ricercati, sulla matrice V.

2.3 Confronto tra partizioni

Trovati gli undici cluster con il k-means confrontiamo la partizione trovata con i "veri" settori GICS, per farlo utilizziamo un indice normalizzato, l'ARI (Adjusted Rand Index); questo varia tra -1 e +1 ed è calcolabile come:

$$ARI = \frac{RI - \mathbb{E}[RI]}{max(RI) - \mathbb{E}[RI]} \tag{9}$$

dove:

- RI è il Rand Index, ovvero la proporzione di coppie di elementi che sono etichettate in modo coerente (sia nello stesso cluster che in cluster diversi) tra le due partizioni.
- $\mathbb{E}[RI]$ è l'aspettativa del Rand Index sotto un modello casuale.
- $max(RI)$ è il massimo valore possibile del Rand Index, pari a 1.

Per calcolare l'ARI in base alle matrici di contingenza delle due partizioni, sia C_1 che C_2, dati:

- n: il numero totale di elementi.
- n_{ij}: il numero di elementi comuni al cluster i di C_1 e al cluster j di C_2.
- $a_i = \sum_j n_{ij}$: il numero totale di elementi nel cluster i di C_1.
- $b_j = \sum_i n_{ij}$: il numero totale di elementi nel cluster j di C_2.

La formula esplicita dell'ARI diventa:

$$\text{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{n}{2}}}{\frac{1}{2}\left(\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\right) - \frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{n}{2}}} \tag{10}$$

in cui:

- $\binom{n_{ij}}{2}$: il numero di coppie che appartengono sia al cluster i in C_1 che al cluster j in C_2.
- Il termine di correzione $\frac{\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}}{\binom{n}{2}}$ rappresenta l'aspettativa del Rand Index in caso di clustering casuale.

Inoltre in base al valore assunto dall'indice è possibile fare alcune osservazioni, in particolare:

- un valore di ARI < 0 suggerisce che il grado di sovrapposizione tra cluster identificati e veri gruppi sia peggiore rispetto a quello casuale;
- un valore di ARI $= 0$ suggerisce che il grado di sovrapposizione tra cluster identificati e veri gruppi sia casuale;
- un valore di $0 >$ ARI > 1 suggerisce un certo grado di sovrapposizione dei cluster identificati con i veri gruppi;
- un valore di ARI $= 1$ identifica perfetta sovrapposizione tra cluster identificati e veri gruppi

3 Risultati

Passiamo ora a valutare i risultati ottenuti dall'analisi condotta seguendo la metodologia appena descritta.

Analizzando il valore assoluto delle correlazioni degli ERR per le singole azioni otteniamo la seguente heatmap, in cui si notano, nella zona in alto a sinistra e in basso a destra, delle "sun spot" con correlazioni abbastanza marcate. Esistono, quindi, dei

comovimenti per gruppi di titoli non dovuti all'andamento del mercato.

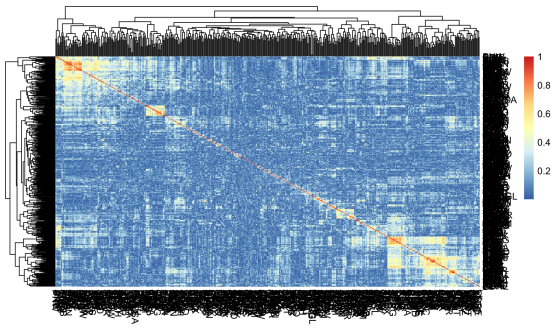


Figura 1: HeatMap delle correlazioni tra gli ERR

Passando all'analisi della partizione creata attraverso l'utilizzo del k-means con undici gruppi, questa riporta una frazione tra BetweenSS e TotalSS di 51.8% indicando che solo una discreta parte della variabilità totale dei dati viene spiegata. Confrontando tale partizione con la partizione delle azioni GICS possiamo creare la seguente visualizzazione per la tabella di contingenza tra i due cluster:

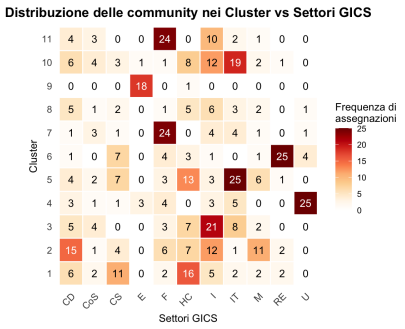


Figura 2: HeatMap delle contingenze tra k-means e settori GICS

La sovrapposizione tra i cluster trovati e i settori GICS rivela informazioni importanti sul funzionamento del mercato; ci sono settori con forte corrispondenza: Energy (E), Utilities (U), Real Estate (RE), Financials (F) e IT (anche se questi ultimi due suddivisi in due clusters). Questi settori mostrano una forte coerenza interna nei pattern di rendimento, suggerendo che le aziende in questi settori tendono a muoversi insieme anche dopo aver rimosso l'effetto del mercato generale.

Al contrario, ci sono settori con corrispondenza più debole: Consumer Discretionary (CD), Consumer Staples (CS), Communication Services (CoS), Healthcare (HC), Industrials (I) e Materials (M); la minore corrispondenza può indicare in questo caso: maggiore diversificazione interna delle aziende, presenza di sotto-settori con dinamiche diverse, possibili effetti di perturbazione del mercato o interconnessioni cross-settoriali più complesse.

Calcolando, infine, l'Adjusted Rand Index (ARI) pari a 0.148 possiamo dire che i cluster identificati attraverso i rendimenti differiscono significativamente dalla classificazione GICS, indicando potenzialmente: la presenza di fattori di rischio che attraversano i confini settoriali tradizionali, possibili inefficienze nella classificazione settoriale tradizionale oppure l'esistenza di dinamiche di mercato che non seguono le divisioni settoriali convenzionali.

4 Conclusioni e sviluppi futuri

L'analisi condotta sul mercato azionario S&P500 nell'ultimo trimestre del 2024 ha rivelato importanti discrepanze tra la classificazione settoriale GICS tradizionale e la struttura di correlazione effettiva dei rendimenti azionari. Attraverso l'applicazione dello spectral clustering, abbiamo identificato pattern di correlazione che suggeriscono una dinamica di mercato più complessa rispetto alla semplice suddivisione in 11 settori GICS. Il valore dell'ARI tra i cluster spettrali e i settori GICS ha mostrato risultati interessanti; l'analisi, condotta sugli extra-rendimenti giornalieri, ha prodotto un ARI di 0.148, indicando una significativa divergenza tra la classificazione formale e il comportamento reale dei titoli. Questo risultato potrebbe anche sottendere la possibilità della presenza di un meccanismo di perturbazione all'interno del mercato.

Le implicazioni di questo studio sono significative per la gestione del rischio e l'allocazione del portafoglio. Come evidenziato da Bhojraj et al.(2003), il sistema GICS è un ottimo strumento per l'analisi di mercato; i nostri risultati suggeriscono che con uno scarso livello di informazioni tale classificazione risulta non del tutto adeguata, specialmente in periodi di rapido cambiamento, come quello preso in considerazione, caratterizzato da cambiamenti macroeconomici e tecnologici importanti (conflitto medio-orientale, conflitto russo-ucraino, cambio della presidenza USA, AI, ecc.).

Rispetto a quanto visto, invece, riguardo al modo in cui si distribuiscono gli extra-rendimenti in confronto ai settori GICS, è possibile fare alcune considerazioni riguardanti strumenti finanziari settoriali; da quanto visto ci sono settori per cui il solo extra-rendimento risulta una discriminante chiara per l'identificazione del settore, sottolineando in qualche modo che, al netto dei movimenti di mercato, quasi la totalità delle aziende dei settori Energy, Utilities e Real Estate abbiano una struttura dei rendimenti molto simile, questo ci permette di dire che strategie di investimento con portafogli o indici settoriali composti unicamente da uno di questi settori possano risultare maggiormente rischiosi nell'ottica di una ottimizzazione del rischio di portafoglio e riducano in parte i benefici sul rendimento totale dovuti all'effetto diversificazione.

In conclusione, un possibile sviluppo futuro dello studio potrebbe essere quello di indagare più in profondità il motivo per cui per i settori Financials e IT gli extra-rendimenti si distribuiscano su due gruppi abbastanza distinti; oltre alla possibilità di integrare lo studio con gli altri tre livelli gerarchici GICS per verificare se questo tipo di classificazione risulti più efficace aumentando la granularità e la segmentazione del mercato, verificando che i risultati ottenuti siano in linea con quanto provato da Bhojraj et al.[2].

Riferimenti bibliografici

[1] Lloyd, S. (1957). "Least squares quantization in PCM,". *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129-137, March 1982, doi: 10.1109/TIT.1982.1056489.

[2] Bhojraj, Sanjeev and Lee, Charles M.C. and Oler, Derek, What's My Line? A Comparison of Industry Classification Schemes for Capital Market Research (May 19, 2003). Available at SSRN: https://ssrn.com/abstract=356840 or http://dx.doi.org/10.2139/ssrn.356840

[3] MSCI. URL: https://www.msci.com/our-solutions/indexes/gics

[4] Yahoo Finance. URL: https://it.finance.yahoo.com/